UNIVERSITÉ CÔTE D'AZUR | MASTER 2 SLCD

Big Data and NoSQL

Projet 1 – WeatherScope

Un observatoire météorologique historique

Hajer Akid | Année universitaire 2026–2027

Traduction française non officielle – en cas de doute, la version anglaise fait foi.

Groupes	Deux étudiants. Chaque membre doit être capable d'expliquer n'importe quelle partie du travail rendu.
Rendu	Vendredi 6 novembre 2026
Soutenance	Mardi 10 novembre 2026, à 14 h 00
Livrables	Un rapport écrit (10 pages maximum, hors annexes) ; le code source ; une présentation orale de 15 minutes incluant une démonstration en direct, suivie de 10 minutes de questions-réponses avec un défi en direct.

1. Scénario du projet

Un observatoire environnemental régional souhaite étudier des conditions météorologiques inhabituelles à partir de mesures historiques issues de stations de surveillance. Ses analystes doivent identifier des périodes de chaleur ou de précipitations exceptionnelles, comparer le comportement de différentes zones et examiner la fiabilité des observations à l'origine d'un résultat.

Vous êtes chargés de développer **WeatherScope**, un prototype fonctionnel grâce auquel un analyste peut sélectionner un lieu et une période, étudier des événements météorologiques, comparer des zones et obtenir les mesures justificatives. L'observatoire attend que la plateforme reste utilisable à mesure que de nouvelles stations et de nouvelles années d'enregistrements sont intégrées, et il ne fera confiance à un résultat que s'il peut être retracé jusqu'aux observations d'origine.

Le prototype sera d'abord déployé avec un **unique serveur de données local**. Il sera ensuite déployé avec **plusieurs instances de service de données sur le même poste de travail**, afin d'étudier comment la distribution des données modifie les performances d'ingestion et de requête. Les deux déploiements doivent offrir les mêmes fonctionnalités et renvoyer des résultats analytiques identiques.

2. Données

Utilisez le **Global Historical Climatology Network–Daily (GHCN-Daily)** fourni par la National Oceanic and Atmospheric Administration (NOAA) des États-Unis. Cette archive contient les observations météorologiques quotidiennes enregistrées ainsi que des informations sur les stations qui les ont produites.

Ressource	**Source officielle**
Observations par année	https://www.ncei.noaa.gov/pub/data/ghcn/daily/by_year/
Observations par station	https://www.ncei.noaa.gov/pub/data/ghcn/daily/by_station/
Métadonnées des stations	https://www.ncei.noaa.gov/pub/data/ghcn/daily/ghcnd-stations.txt
Format et conventions	https://www.ncei.noaa.gov/pub/data/ghcn/daily/readme.txt
Format CSV	https://www.ncei.noaa.gov/pub/data/ghcn/daily/readme-by_year.txt

Chaque observation contient un identifiant de station, une date, une variable météorologique (*element*), sa valeur enregistrée, un indicateur de mesure (*measurement flag*), un indicateur de

qualité (*quality flag*), un indicateur de source (*source flag*) et, pour certains enregistrements, une heure d'observation. Les métadonnées des stations fournissent les noms, les coordonnées et l'altitude. Les éléments utiles incluent la température maximale quotidienne (`TMAX`), la température minimale quotidienne (`TMIN`) et les précipitations (`PRCP`). Dans les fichiers sources, `TMAX` et `TMIN` sont exprimées en **dixièmes de degré Celsius** et `PRCP` en **dixièmes de millimètre**.

Chaque fichier annuel couvre toutes les stations du monde ; les fichiers par station sont généralement plus pratiques pour un ensemble limité de stations. De nombreuses stations enregistrent leurs valeurs quotidiennes à une heure d'observation fixe, le matin ou le soir : une date calendaire ne couvre donc pas les mêmes 24 heures pour toutes les stations. Discutez des conséquences de ce point pour les comparaisons entre plusieurs stations.

Périmètre et enregistrement

Choisissez un périmètre géographique documenté couvrant **au moins deux zones distinctes** et **au moins huit années civiles consécutives**. La notion de zone (rectangle englobant, pays, État, rayon autour d'un point, ...) est à vous de définir et de justifier. Le sous-ensemble sélectionné doit contenir **au moins 100 stations** et **200 000 couples station–jour distincts** (un couple station–jour compte si au moins l'une des valeurs `TMAX`, `TMIN` ou `PRCP` est enregistrée pour ce jour) ; tout ajustement doit être justifié par la disponibilité mesurée des observations ou par des contraintes matérielles.

Chaque groupe enregistre son périmètre (zones, années, période de référence envisagée) auprès de l'enseignante **avant de commencer l'implémentation**. Deux groupes ne peuvent pas enregistrer la même paire de zones ; l'enseignante peut demander à un groupe de modifier un périmètre qui chevauche trop celui d'un autre. L'enseignante utilisera les périmètres enregistrés pour préparer les défis de la soutenance (section 6).

Provenance et qualité

L'archive est révisée en continu : le même fichier téléchargé à deux dates différentes peut différer. Enregistrez la date de récupération, la liste exacte des fichiers sources et une somme de contrôle (*checksum*) de chacun d'eux. Indiquez le nombre de stations, de couples station–jour et d'observations exploitables pour chaque élément analysé, et caractérisez la couverture temporelle, la répartition géographique et les données manquantes.

En annexe, documentez **au moins cinq anomalies de données réellement présentes dans votre sous-ensemble** (par exemple : valeurs signalées par un indicateur, valeurs physiquement invraisemblables, couples `TMAX`/`TMIN` incohérents, lacunes, stations dont l'enregistrement commence ou s'arrête au cours de la période), chacune avec sa fréquence et au moins une station et une date concrètes. Ces exemples seront vérifiés par rapport aux fichiers de la NOAA.

L'application et les bancs d'essai doivent utiliser **uniquement des observations réelles**. Ne fabriquez pas de mesures, ne dupliquez pas d'enregistrements pour gonfler le jeu de données et ne comptez pas les copies répliquées comme de nouvelles observations.

Expliquez comment sont traités les historiques incomplets, les enregistrements sources dupliqués, les valeurs inhabituelles, les indicateurs de qualité et les indicateurs de mesure. En particulier, les valeurs de précipitations portant l'indicateur de mesure `P` (manquante, présumée nulle) ou `T` (trace) ne doivent pas être utilisées comme des zéros ordinaires sans justification.

3. Système à développer

WeatherScope doit exposer les services suivants via une interface utilisable (interface web, API ou application en ligne de commande). Les paramètres de requête doivent être fournis à l'exécution, et les résultats doivent être calculés à partir des données stockées. Les agrégats précalculés ou les vues matérialisées sont autorisés si le système les maintient et si F5 les tient à jour ; les réponses préparées à l'avance pour des exemples fixes, ou les tables assemblées à la main, ne le sont pas.

F1. Explorer une station. Rechercher des stations dans une zone géographique, sélectionner une station et récupérer ses mesures sur un intervalle de dates choisi. Présenter un résumé temporel accompagné de la disponibilité et de la qualité des observations sous-jacentes.

F2. Étudier des événements prolongés. Étant donnés une zone géographique, une période et un critère d'événement défini par l'utilisateur, identifier les épisodes de jours consécutifs caractérisés par une chaleur ou des précipitations exceptionnelles. Renvoyer les stations concernées, les dates de début et de fin, la durée de l'événement et une mesure de son intensité. Les jours manquants et les observations présentant des problèmes de qualité ne doivent pas créer ou prolonger silencieusement des épisodes, et **un épisode qui chevauche deux années doit être signalé comme un seul épisode**.

F3. Comparer les conditions historiques. Pour des zones et des années sélectionnées, identifier les mois qui s'écartent le plus fortement du comportement saisonnier habituel en température ou en précipitations. Produire une comparaison classée qui tienne compte des différences de couverture des stations et de disponibilité des observations. Définir et justifier la référence historique et l'éligibilité des périodes incomplètes. La période de référence peut s'étendre au-delà de la période d'étude ; les observations utilisées uniquement comme référence doivent être chargées via le même pipeline et comptées séparément dans le rapport. Les normales climatologiques sont conventionnellement calculées sur 30 ans : si votre période de référence est nettement plus courte, discutez-en les conséquences statistiques.

F4. Identifier des événements régionaux. Trouver des périodes durant lesquelles plusieurs stations d'une même zone connaissent des conditions inhabituelles sur des dates qui se chevauchent. Distinguer un extrême isolé à une station d'un événement touchant une zone géographique plus large, en tenant compte du fait que la densité des stations n'est pas uniforme. Renvoyer des éléments justifiant les événements détectés ainsi que leur sévérité relative.

F5. Mettre à jour l'archive. Importer un lot supplémentaire d'observations NOAA authentiques (par exemple une année ou un ensemble de stations exclus du chargement initial) sans perdre les données précédentes ni créer de doublons. Définir l'identité d'une observation et une politique justifiée pour les enregistrements qui existent déjà avec une valeur ou un indicateur différent (écraser, conserver un historique ou rejeter). **Importer deux fois le même lot doit laisser l'archive inchangée.** De véritables révisions n'apparaissent qu'entre deux téléchargements effectués à des dates différentes : la politique doit être implémentée, mais la tester sur de véritables enregistrements révisés est facultatif. La mise à jour doit fonctionner sur les deux déploiements, et les services ci-dessus doivent refléter l'archive mise à jour.

Pour chaque service, documentez ses entrées et ses sorties et donnez au moins un exemple significatif obtenu à partir du jeu de données sélectionné. **Tout événement signalé doit être traçable jusqu'à ses observations sources** : étant donné un résultat, le système doit pouvoir lister les enregistrements sous-jacents (station, date, élément, valeur, indicateurs).

4. Implémentation et distribution

Partie I – Prototype local

Concevez l'organisation des données et implémentez les cinq services sur un unique serveur de données local, c'est-à-dire un système de base de données s'exécutant comme **processus serveur séparé**, interrogé par l'application via un point d'accès réseau (une bibliothèque embarquée telle que SQLite ou DuckDB n'est acceptée que si elle est encapsulée dans un tel processus serveur). Le rapport doit présenter la structure des informations stockées, les raisons du choix de la technologie

de gestion de données, les principaux schémas d'accès et les mécanismes employés pour rendre efficaces les opérations requises.

Utilisez des résultats d'exécution réels pour justifier au moins une décision de conception importante. **Implémentez et mesurez une conception alternative** (modèle de données, indexation ou organisation physique) sur les mêmes données et sur au moins deux requêtes représentatives, et expliquez pourquoi elle a été retenue ou rejetée. L'ensemble de la procédure d'acquisition et de chargement doit être reproductible.

Partie II – Prototype distribué

Déployez une seconde version utilisant **au moins deux instances de service de données distinctes**, s'exécutant comme processus ou conteneurs avec des emplacements de stockage et des points de communication distincts. Une instance de service de données est un serveur de base de données ou de stockage qui stocke une partie des observations et répond aux requêtes portant sur celles-ci ; un moteur de traitement seul (par exemple Spark lisant des fichiers) ne compte pas comme tel. Les observations doivent être **réparties** entre les instances, et non simplement copiées intégralement sur chacune d'elles. WeatherScope doit continuer à exposer une interface unique et cohérente à ses utilisateurs.

Définissez et justifiez la stratégie de placement des données. Pour des requêtes représentatives, montrez quelles instances sont contactées et comment les résultats partiels sont combinés. Opposez les requêtes à portée géographique et temporelle étroite aux requêtes impliquant de vastes zones ou de longs historiques. Évaluez l'effet de l'organisation choisie sur l'équilibre des données, les écritures et les analyses multi-stations. Vérifiez que les versions locale et distribuée produisent des réponses identiques pour les mêmes observations et les mêmes requêtes, à l'aide d'une **comparaison automatisée**. Comparez les résultats après un tri canonique, les égalités étant départagées de manière déterministe. La comparaison doit inclure des requêtes dont la plage temporelle ou l'ensemble de stations s'étend sur plusieurs instances.

Implémentez et évaluez une configuration distribuée alternative, en modifiant soit la politique de placement, soit le nombre d'instances de service de données.

Perte d'une instance. Arrêtez une instance de service de données et exécutez F1 sur une station stockée sur cette instance, puis F3. Montrez ce que reçoit l'utilisateur. **Une réponse partielle ne doit jamais être présentée comme complète** : soit la requête échoue explicitement, soit la réponse indique quelles données étaient indisponibles. Distinguez ce que votre implémentation récupère réellement de ce qu'un système de production répliqué pourrait récupérer. Un déploiement multi-processus sur un seul poste ne doit pas être présenté comme équivalent à un cluster de machines indépendantes.

5. Étude expérimentale

L'observatoire utilisera WeatherScope de deux manières différentes : l'examen courant d'un nombre limité de stations sur de courtes périodes, et des études régionales occasionnelles couvrant de nombreuses stations et années.

E1. Volume de données croissant. Évaluez l'ingestion et des requêtes de service représentatives sur trois sous-ensembles de plus en plus grands de l'archive réelle. Le plus grand sous-ensemble doit contenir **au moins 10 millions d'observations brutes** de `TMAX`, `TMIN` et `PRCP`, obtenues à partir de stations ou d'années réelles supplémentaires (les fichiers par année peuvent être nécessaires) ; les observations chargées pour la période de référence comptent dans ce total. Indiquez si le plus grand sous-ensemble tient encore dans la mémoire disponible pour votre base de données. Relevez le nombre d'observations, les temps d'exécution et l'espace de stockage requis.

E2. Fonctionnement local ou distribué. Comparez le déploiement local et les deux configurations distribuées sur des données et des requêtes de service identiques, en utilisant le plus grand sous-ensemble de E1 (E3 utilise les mêmes données). Incluez une requête étroite, une agrégation sur une longue période et une analyse impliquant plusieurs stations. Présentez des mesures répétées avec tendance centrale et variabilité, et précisez les conditions de cache et de préchauffage (*warm-up*).

E3. Charge de travail variable. Construisez deux charges de travail reflétant les modes « routine » et « étude régionale » de l'observatoire. Choisissez au moins deux de vos trois configurations à comparer. **Avant d'effectuer les mesures**, écrivez laquelle vous vous attendez à voir la plus performante sous chaque charge de travail et pourquoi, et **déposez cette prédiction sur la plateforme du cours** (ou envoyez-la à l'enseignante). Faites varier la fréquence relative des deux types de requêtes et confrontez les prédictions aux résultats mesurés. Une prédiction erronée mais bien expliquée est valorisée autant qu'une prédiction correcte.

E4. Une limite de votre conception (facultatif). Cette expérience est facultative et compte comme bonus. Trouvez un cas, tiré de la distribution géographique ou temporelle réelle des observations, où l'architecture choisie est peu performante ou produit un résultat potentiellement trompeur. Déterminez-en la cause, apportez une modification bien motivée et mesurez son effet. Discutez de toute amélioration obtenue au détriment d'autres opérations ou ressources.

Les résultats doivent inclure les versions matérielles et logicielles, les limites de ressources, les paramètres de requête, les temps mesurés, les observations pertinentes au niveau des instances et une explication des différences. Sur un seul poste de travail, plusieurs processus de service de données partagent toujours le CPU, la mémoire et le disque ; tenez-en compte dans l'interprétation de l'impact de la distribution, et ne supposez pas qu'ajouter des instances améliore les performances.

Vérification indépendante. Vérifiez au moins deux résultats analytiques non triviaux (un issu de F2 et un issu de F3 ou F4) à l'aide d'un **script séparé qui lit directement les fichiers NOAA originaux**, sans utiliser votre base de données.

6. Rendu et soutenance

Contenu du rendu

Pour le **vendredi 6 novembre 2026**, rendez :

- le rapport écrit (10 pages maximum, hors annexes) présentant le système, l'architecture, les résultats vérifiés, les expériences et les limites ;
- le code source complet et les fichiers de configuration ;
- les mesures brutes utilisées dans les comparaisons ;
- un README contenant les instructions d'installation et d'exécution permettant de reproduire les principales expériences.

Soutenance

Chaque groupe fait une présentation de 15 minutes, incluant une démonstration en direct d'au plus cinq minutes, suivie d'une séance de questions-réponses de 10 minutes. Pendant les questions, le groupe affrontera un **défi en direct** préparé à partir de son périmètre enregistré, par exemple :

- exécuter des services avec de nouveaux paramètres choisis par le jury ;
- importer, via F5, un extrait NOAA authentique fourni lors de la soutenance, puis montrer que les résultats changent en conséquence ;

- retracer un résultat signalé jusqu'à ses enregistrements sources ;
- expliquer un fichier ou une fonction du code source choisi par le jury, par un membre du groupe également choisi par le jury.